

Karta Produktu Danych

MovieLens 32M Daily Ratings

Data utworzenia 11.05.26r.

Autor: Marcin Hyla PJATK s36699

Repozytorium Git: https://github.com/matcingq/BGD_3/tree/main

1. Czym jest produkt danych:

Produkt danych zawiera metryki ocen filmów na podstawie ogólnodostępnego zbioru MovieLens 32M (<https://files.grouplens.org/datasets/movielens/ml-32m.zip>).

Wynikiem końcowym jest plik Parquet zawierający warstwę Gold: liczbę ocen, średnią, minimum oraz maksimum ocen.

2. Jaki problem rozwiązuje:

Produkt umożliwia analizę popularności filmów, a także ich odbiór w czasie. Pozwala na szybką analizę pytań takich jak: jaki film jest oceniany najczęściej (można zakładać że ilość ocen jest wprost proporcjonalna do popularności filmu), lub jaki film jest najbardziej polaryzujący.

3. Źródła danych:

Źródło: MovieLens 32M

Link: (<https://files.grouplens.org/datasets/movielens/ml-32m.zip>).

Pliki wejściowe: ratings.csv, movies.csv

4. Dostęp do produktu i sposób uruchomienia:

Repozytorium Git: https://github.com/matcingq/BGD_3/tree/main

Uruchomienie pipeline: python3 run_pipeline.py

Lokalizacja produktu finalnego (warstwy Gold):

data/medallion/gold/movie_daily_metrics

Dostęp do repozytorium Git jest otwarty.

5. Schemat produktu końcowego:

Kolumna	Typ	Opis
rating_date	date	Dzień pobrania
movie_id	long	Id filmu
title	string	Tytuł filmu
ratings_count	long	Liczba ocen filmu danego dnia
avg_ratings	double	Średnia ocen filmu danego dnia
min_ratings	double	Najniższa ocena filmu danego dnia
max_ratings	double	Najwyższa ocena filmu danego dnia

6. Kluczowe metryki jakości danych:

Pomiar z testu pipeline: 10.05.26r.

Metryka	Definicja	Wartość	Próg	Cadence
dq_completeness_rating_pct	Procent rekordów z niepustym "rating"	100%	>= 99%	Po każdym runie pipeline'u
dq_uniqueness_movie_id_pct	Procent unikalnych filmów (po Id) w Bronze	100%	= 100%	Po każdym runie pipeline'u
dq_valid_rating_range_pct	Procent ratingów w poprawnym zakresie (0.5-5)	100%	>= 99%	Po każdym runie pipeline'u
dq_freshness_hours	Godziny ostatniego "ingested_at"	0.0h	<= 24h	Po każdym runie pipeline'u

7. Znane ograniczenia:

Działa lokalnie i wymaga instalacji Spark (a zatem również Java).

Warstwy danych są nadpisywane

8. Przykład (PySpark):

```
from pyspark.sql import SparkSession
spark = SparkSession.builder.master("local[2]").appName("read-gold").getOrCreate()
gold = spark.read.parquet("data/medallion/gold/movie_daily_metrics")
gold.orderBy("rating_date", ascending=False).show(20, truncate=False)
```

9. Podsumowanie wartości biznesowej:

Produkt umożliwia przygotowanie wizualizacji trendów na podstawie ocen filmów, zmiany tego, jak widzowie oceniają dany film na podstawie upływu czasu od premiery lub analizę największej koncentracji wystawiania ocen w czasie. Jest to produkt użyteczny dla fanów kina, jak również dla osób zajmujących się marketingiem, którym pomóc może w ocenie np. skuteczności kampanii marketingowej.